TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ HỌA MÁY TÍNH

BÀI TẬP LỚP NHÀ

Giảng viên: Thầy Lý Quốc Ngọc

Sinh viên thực hiện:

Họ và tên	Mã số sinh viên	Lớp
Tô Thành Đạt	24127153	24TGMT
Lương Hưng Phát	24127298	24TGMT
Nguyễn Nhựt Huy	24127398	24TGMT

TP. Hồ Chí Minh, tháng 10/2026

BÀI TẬP LỚP NHÀ: NHÓM GITREMOVEALL

Tô Thành Đạt – 24127153
Khoa Công nghệ Thông tin
Trường ĐH Khoa học Tự nhiên
24127153@student.hcmus.edu.vn

Lương Hưng Phát – 24127298
Khoa Công nghệ Thông tin
Trường ĐH Khoa học Tự nhiên
24127298@student.hcmus.edu.vn

Nguyễn Nhựt Huy – 24127398
Khoa Công nghệ Thông tin
Trường ĐH Khoa học Tự nhiên
24127398@student.hcmus.edu.vn

ABSTRACT

Báo cáo này tổng hợp toàn bộ nội dung bài học, câu hỏi lý thuyết và bài tập môn Đồ họa Máy tính (Computer Graphics) theo lộ trình 12 tuần học.

MỤC LỤC

1 Tuần 1: Tổng quan Khoa học Dữ liệu Thị giác & Computer Graphics **3**

1.1 Đối tượng nghiên cứu của Khoa học Dữ liệu Thị giác và Dữ liệu Đa phương thức . 3
1.2 Mục tiêu và bản chất của cuộc Cách mạng Công nghiệp 4.0 3
1.3 Tiến trình phát triển kỹ thuật qua 4 cuộc Cách mạng Công nghiệp 3
1.4 Vai trò của dữ liệu thị giác trong sản xuất và quản lý xã hội 4
1.5 Tác động của dữ liệu thị giác trên các quy trình sản xuất ngành nghề 4
1.6 Nguồn gốc dữ liệu thị giác và Sự khác biệt giữa mắt người và thiết bị thu nhận hình ảnh 5
1.7 Hệ thống các loại đặc trưng trong dữ liệu thị giác 5
1.8 Khái niệm đối tượng trong dữ liệu thị giác: Phân biệt cấp độ lớp và cấp độ thực thể 5
1.9 Bản chất và thách thức của khoảng cách ngữ nghĩa (Semantic Gap) 6
1.10 Tiến trình phát triển trong việc thu hẹp khoảng cách ngữ nghĩa 6
1.11 Động lực mở rộng từ dữ liệu hình ảnh sang dữ liệu đa phương thức 6
1.12 Phân định ranh giới giữa Đồ họa máy tính, Xử lý ảnh và Thị giác máy tính 7
1.13 Khái quát các bài toán cốt lõi trong Thị giác máy tính 7
1.14 So sánh bài toán Nhận dạng (Recognition) và Truy vấn ảnh (Image Retrieval) . . . 10
1.15 So sánh bài toán Truy vấn ảnh (Retrieval) và Theo dõi đối tượng (Tracking) 10
1.16 So sánh bài toán Đếm đối tượng (Counting) và Phát hiện đối tượng (Object Detection) 10
1.17 Mô hình Tạo sinh (Generative) và tương quan với các tác vụ Phân tích (Discriminative) 10

2 Tuần 2: Trí tuệ Nhân tạo, Học máy & Học sâu trong Khoa học Dữ liệu Thị giác **12**

2.1 Bản chất của Trí tuệ Tự nhiên, Trí tuệ Nhân tạo và Khái niệm Thông minh 12
2.2 Tác động của Trí tuệ Nhân tạo đối với sự phát triển của Trí tuệ Tự nhiên 13

2.3 Phân định bản chất giữa Thông minh (Intelligence) và Thông tuệ (Wisdom) 15
2.4 Giải thích Luận điểm: “Thông minh là Khả năng Thích ứng với sự Thay đổi” . . . 15
2.5 Bản chất của Học máy: Phân tích tư tưởng Arthur Samuel (1959) 15
2.6 Định nghĩa Hình thức về Học máy theo Tom Mitchell (1997) 16
2.7 Tiến trình Chuyển tiếp từ Học máy sang Học sâu: Giới hạn và Động lực Đột phá . . 16
2.8 Nền tảng của Học sâu: Vì sao Nguyên lý Đơn giản tạo nên Khả năng Biểu diễn Vượt trội? 17
2.9 Mô hình 5 Cấp độ Nhận thức và Dữ liệu: Ứng dụng Giám sát An ninh Trường học . 17
2.10 Mô hình Giải pháp 3 Tầng trong Khoa học Dữ liệu Thị giác 18
2.11 Khái quát các Nhóm Ứng dụng Cơ bản của Thị giác Máy tính 19
2.12 Phân tích Chuyên sâu: Ứng dụng Trí tuệ Nhân tạo trong Ngành Điện ảnh 19
2.13 Ý nghĩa Thực tiễn của Bài toán Đếm Đám đông ở Tầng Ứng dụng Nghiệp vụ . . . 19
2.14 Phân tích Hệ thống Tái tạo Khuôn mặt 3D theo Mô hình Giải pháp 3 Tầng 20

1 Tuần 1: Tổng quan Khoa học Dữ liệu Thị giác & Computer Graphics

1.1 Đối tượng nghiên cứu của Khoa học Dữ liệu Thị giác và Dữ liệu Đa phương thức

Khoa học Dữ liệu Thị giác (Visual Data Science) là lĩnh vực liên ngành nghiên cứu các nguyên lý toán học, cấu trúc dữ liệu và mô hình tính toán nhằm thu thập, biểu diễn, trích xuất đặc trưng và suy luận tri thức từ dữ liệu trực quan. Miền dữ liệu này bao gồm hình ảnh số 2D, chuỗi khung hình video có tính tương quan thời gian, đám mây điểm 3D (Point Clouds) từ thiết bị quét laser, dữ liệu thể tích voxel trong chẩn đoán y khoa (chụp cắt lớp vi tính CT, cộng hưởng từ MRI), cho đến ảnh viễn thám đa phổ từ vệ tinh.

Nhằm vượt qua giới hạn biểu diễn của từng kênh cảm biến đơn lẻ, ngành khoa học này đã mở rộng phạm vi sang dữ liệu đa phương thức (Multimodal Data). Việc thiết lập liên kết biểu diễn giữa dữ liệu thị giác với các phương thức khác như văn bản tự nhiên, tín hiệu âm thanh hay chuỗi đo lường quán tính (IMU) cho phép giải quyết các bài toán nhận thức không gian và ngữ cảnh phức tạp. Điển hình cho hướng tiếp cận này là bài toán phân đoạn đối tượng trong video dựa trên mô tả hành động bằng văn bản hoặc âm thanh dẫn đường (Referring Motion Expression Video Segmentation) (Ding et al., 2025). Thay vì chỉ định mục tiêu bằng các chỉ số lớp cố định, mô hình tiếp nhận câu mô tả tự nhiên hoặc âm thanh đặc trưng để khoanh vùng chính xác mặt nạ pixel (segmentation mask) của đối tượng chuyển động xuyên suốt các khung hình.

1.2 Mục tiêu và bản chất của cuộc Cách mạng Công nghiệp 4.0

Trọng tâm của cuộc Cách mạng Công nghiệp 4.0 là quá trình thông minh hóa (Smartification) toàn diện các quy trình sản xuất công nghiệp và hệ thống quản trị xã hội trên nền tảng chuyển đổi số.

Quá trình thông minh hóa được hiện thực hóa thông qua việc tích hợp các mô hình học máy và mạng lưới cảm biến vạn vật (IoT) vào thiết bị phần cứng. Nhờ đó, hệ thống kỹ thuật đạt được năng lực tự thu thập dữ liệu môi trường, tự hiệu chỉnh thông số vận hành và ra quyết định tối ưu theo thời gian thực mà **không cần sự can thiệp thủ công liên tục từ con người**.

Trong lĩnh vực sản xuất công nghiệp, quá trình này giúp nâng cao năng suất lao động, giảm thiểu chi phí vận hành, loại bỏ sai sót chủ quan và hiện thực hóa mô hình cá nhân hóa sản phẩm hàng loạt (Mass Customization). Trong quản trị xã hội, việc triển khai các hệ thống điều khiển giao thông thích ứng, lưới điện thông minh và nền tảng y tế số góp phần tối ưu hóa dịch vụ công và phân bổ nguồn lực đô thị minh bạch, hiệu quả.

Tiến trình chuyển đổi công nghệ trong kỷ nguyên mới diễn ra qua ba cấp độ kế thừa:

1. **Số hóa dữ liệu (Digitization):** Quá trình chuyển đổi dữ liệu từ dạng vật lý hoặc tương tự (tài liệu giấy, hình ảnh chụp, băng từ analog) sang định dạng nhị phân số.
2. **Số hóa quy trình (Digitalization):** Việc ứng dụng công nghệ kỹ thuật số và dữ liệu đã số hóa vào việc tối ưu hóa hoặc tự động hóa các quy trình nghiệp vụ sẵn có mà chưa làm thay đổi bản chất mô hình vận hành tổng thể.
3. **Chuyển đổi số (Digital Transformation):** Sự tái cấu trúc toàn diện mô hình hoạt động, quy trình nghiệp vụ, phương pháp ra quyết định và văn hóa tổ chức dựa trên việc khai thác dữ liệu và trí tuệ nhân tạo.

Trong hệ sinh thái công nghệ 4.0, các ngành khoa học cơ bản như Toán học, Vật lý, Hóa học và Sinh học đóng vai trò nền tảng trong việc xây dựng cơ sở lý thuyết và chế tạo linh kiện bán dẫn, cảm biến quang học. Tuy nhiên, Trí tuệ nhân tạo (AI) đóng vai trò cốt lõi bởi đây là công cụ tính toán duy nhất có khả năng trích xuất tri thức từ các tập dữ liệu phi cấu trúc khổng lồ và đưa ra quyết định tự hành trong môi trường thay đổi liên tục.

1.3 Tiến trình phát triển kỹ thuật qua 4 cuộc Cách mạng Công nghiệp

Lịch sử phát triển sản xuất của văn minh nhân loại được đánh dấu qua 4 bước chuyển dịch công nghệ nền tảng:

Cách mạng Công nghiệp 1.0 (Cuối thế kỷ 18 đến đầu thế kỷ 19): Khởi đầu từ việc thương mại hóa động cơ hơi nước và ứng dụng cơ giới hóa vào ngành dệt. Bước tiến này đã thay thế sức kéo cơ bắp của con người và động vật bằng năng lượng cơ khí, đặt nền móng cho các đô thị công nghiệp đầu tiên.

Cách mạng Công nghiệp 2.0 (Cuối thế kỷ 19 đến đầu thế kỷ 20): Được thúc đẩy bởi việc phát minh ra năng lượng điện, động cơ đốt trong và dây chuyền lắp ráp liên tục (Assembly Line). Đột phá này đưa phương thức sản xuất hàng loạt với chi phí thấp trở thành chuẩn mực công nghiệp, đồng thời thúc đẩy sự bùng nổ của mạng lưới giao thông vận tải và viễn thông hiện đại.

Cách mạng Công nghiệp 3.0 (Thập niên 1960 đến cuối thế kỷ 20): Chuyển trọng tâm sang công nghệ bán dẫn, máy vi tính cá nhân và mạng Internet. Sự ra đời của các bộ điều khiển logic lập trình được (PLC) trong tự động hóa nhà máy đã thay đổi căn bản cách thức vận hành công nghiệp và mở ra kỷ nguyên số hóa thông tin.

Cách mạng Công nghiệp 4.0 (Từ đầu thế kỷ 21 đến nay): Hướng tới xây dựng các hệ thống không gian mạng - vật lý (Cyber-Physical Systems - CPS), nơi thế giới thực và mô hình số đồng bộ hai chiều thông qua AI, IoT, dữ liệu lớn và điện toán đám mây, tiến tới mô hình nhà máy tự hành và đô thị thông minh.

1.4 Vai trò của dữ liệu thị giác trong sản xuất và quản lý xã hội

Xét về mặt nhận thức sinh học, thị giác cung cấp hơn 80% tổng lượng thông tin mà con người tiếp nhận từ thế giới xung quanh. Dưới góc độ kỹ thuật, dữ liệu thị giác đại diện cho phương thức thu thập thông tin không tiếp xúc (non-contact) và không phá hủy mẫu vật (non-destructive), mang lại mật độ thông tin không gian - thời gian vượt trội so với các loại cảm biến đo điểm truyền thống.

Trong sản xuất công nghiệp, hệ thống camera thị giác máy tính quét bề mặt sản phẩm với tần số cao để đo đạc kích thước hình học, kiểm tra độ phẳng và phát hiện khuyết tật vật liệu theo thời gian thực. Trong quản lý xã hội, luồng dữ liệu hình ảnh và video từ camera giám sát đô thị cùng ảnh vệ tinh viễn thám cung cấp thông tin không gian chi tiết, phục vụ công tác điều phối giao thông, phát hiện ùn tắc, giám sát an ninh trật tự và ứng phó thiên tai kịp thời.

1.5 Tác động của dữ liệu thị giác trên các quy trình sản xuất ngành nghề

Ứng dụng của dữ liệu thị giác hiện diện sâu rộng trong nhiều lĩnh vực sản xuất và quản lý tài nguyên:

Trong công nghiệp sản xuất và chế tạo cơ khí: Dữ liệu thị giác đóng vai trò cốt lõi trong hệ thống kiểm tra quang học tự động (Automated Optical Inspection - AOI) nhằm phát hiện các vết nứt vi mô, lỗi hàn vi mạch trên bo mạch điện tử với độ chính xác micromet. Đồng thời, thị giác robot (Vision-Guided Robotics) cung cấp tọa độ không gian 3D để cánh tay robot tự động gắp thả linh kiện, hàn điểm và lắp ráp phụ tùng trên dây chuyền tốc độ cao. Ngoài ra, hệ thống camera thông minh còn giám sát việc chấp hành trang bị bảo hộ cá nhân (PPE) và cảnh báo công nhân khi bước vào vùng nguy hiểm quanh máy móc nặng.

Trong nông nghiệp công nghệ cao: Hình ảnh kỹ thuật số hỗ trợ phân loại nông sản tự động sau thu hoạch dựa trên kích thước, màu sắc, độ chín và phát hiện dị tật bề mặt. Trên cánh đồng, camera gắn trên máy bay không người lái (drone) kết hợp thuật toán thị giác giúp phát hiện sớm sâu bệnh và nấm lá, cho phép phun thuốc bảo vệ thực vật chính xác theo từng cụm cây nhiễm bệnh. Ảnh đa phổ từ drone còn được sử dụng để tính toán chỉ số sinh khối (NDVI), hỗ trợ dự báo năng suất mùa màng chính xác.

Trong lâm nghiệp và quản lý môi trường: Dữ liệu ảnh vệ tinh đa thời gian được phân tích để theo dõi diễn biến độ che phủ rừng, phát hiện kịp thời các hoạt động phá rừng hoặc lấn chiếm đất lâm nghiệp trái phép. Bên cạnh đó, hệ thống camera nhiệt và camera quang học tầm xa đặt tại các tháp quan sát hỗ trợ phát hiện sớm cột khói và các điểm cháy rừng bất thường từ khoảng cách hàng chục kilômét.

1.6 Nguồn gốc dữ liệu thị giác và Sự khác biệt giữa mắt người và thiết bị thu nhận hình ảnh

Dữ liệu thị giác được thu thập từ đa dạng các loại cảm biến quang điện tử: camera quang học dải khả kiến (cảm biến CCD/CMOS), camera nhiệt hồng ngoại, thiết bị quét laser LiDAR, cảm biến thời gian bay (Time-of-Flight - ToF), thiết bị chụp cắt lớp y tế (X-ray, CT, MRI, siêu âm) cũng như dữ liệu tổng hợp từ các engine đồ họa 3D.

Xét về mặt cơ chế thu nhận và xử lý, giữa hệ thống thị giác sinh học của con người và thiết bị thu nhận ảnh kỹ thuật số tồn tại những khác biệt nền tảng:

Cơ chế cảm nhận và xử lý tín hiệu: Võng mạc mắt người chứa hàng triệu tế bào thụ cảm quang phân bố không đồng đều, gồm tế bào que cảm nhận độ sáng trong điều kiện thiếu sáng và tế bào nón cảm nhận màu sắc tập trung với mật độ cao nhất tại vùng hoàng điểm (fovea). Tín hiệu thị giác được tiền xử lý cục bộ ngay tại các tầng tế bào thần kinh võng mạc trước khi truyền qua dây thần kinh thị giác lên vỏ não. Ngược lại, cảm biến máy ảnh kỹ thuật số sử dụng mảng lưới điểm ảnh đồng nhất được phủ bộ lọc màu Bayer (RGB), thực hiện biến đổi tuyến tính photon ánh sáng thành điện tích để tạo ra ma trận số thô.

Dải động học (Dynamic Range): Mắt người sở hữu khả năng thích ứng động học linh hoạt vượt quá 20 stop ($> 100,000 : 1$), cho phép nhận biết đồng thời các chi tiết nằm trong vùng bóng râm sâu và vùng nguồn sáng chói. Cảm biến kỹ thuật số thương mại thông thường chỉ đạt dải động khoảng 10–14 stop, dễ dẫn đến hiện tượng cháy sáng ở vùng quá sáng hoặc mất chi tiết do nhiễu ở vùng tối.

Dải phổ điện từ (Spectral Range): Thị giác con người bị giới hạn nghiêm ngặt trong dải ánh sáng khả kiến với bước sóng từ 380 nm đến 740 nm. Thiết bị thu nhận nhân tạo có thể mở rộng độ nhạy quang phổ sang tia X, tia tử ngoại, dải hồng ngoại gần, hồng ngoại nhiệt và sóng radar vô tuyến.

Độ chính xác định lượng và tính ổn định: Thiết bị quang học đo lường cường độ bức xạ ánh sáng bằng các giá trị số học tuyệt đối và hoạt động liên tục với tính ổn định cao. Ngược lại, nhận thức thị giác của con người mang tính định tính, chịu sự chi phối của tâm lý học nhận thức và dễ bị suy giảm độ chính xác do ảo ảnh thị giác hoặc mệt mỏi thể chất.

1.7 Hệ thống các loại đặc trưng trong dữ liệu thị giác

Bên cạnh các đặc trưng thị giác mức thấp (màu sắc, kết cấu texture, hình dạng đường biên) và đặc trưng ngữ nghĩa mức cao (nhãn phân loại lớp đối tượng), việc biểu diễn dữ liệu thị giác hiện đại còn khai thác nhiều nhóm đặc trưng chuyên sâu:

Đặc trưng không gian (Spatial Features): Bao gồm độ sâu từng pixel, tọa độ không gian 3D thực tế, vector pháp tuyến bề mặt, góc xoay và tịnh tiến 6 bậc tự do (6-DoF Pose), cấu trúc đám mây điểm và lưới đa giác 3D (Polygon Mesh).

Đặc trưng thời gian (Temporal Features): Bao gồm luồng quang học (Optical Flow) biểu diễn vector chuyển động của từng pixel giữa hai khung hình liên tiếp (u, v), quỹ đạo di chuyển của đối tượng qua thời gian, cùng vận tốc và gia tốc chuyển động.

Đặc trưng cấu trúc và quan hệ (Relational Features): Được mô hình hóa dưới dạng Đồ thị quan hệ cảnh (Scene Graphs), trong đó các nút đại diện cho các thực thể và các cạnh mô tả quan hệ không gian hoặc tương tác người - vật (Human-Object Interaction - HOI), giúp hệ thống nắm bắt ngữ cảnh toàn diện thay vì các đối tượng đơn lẻ.

Đặc trưng thống kê và tần số (Statistical Features): Bao gồm phổ tần số không gian thông qua biến đổi Fourier, biểu diễn đa tỷ lệ qua biến đổi Wavelet, ma trận đồng xuất mức xám (GLCM) và ma trận hiệp phương sai đặc trưng.

1.8 Khái niệm đối tượng trong dữ liệu thị giác: Phân biệt cấp độ lớp và cấp độ thực thể

Trong thị giác máy tính, một đối tượng thị giác (Visual Object) là một vùng không gian hoặc tập hợp các pixel liên thông tương ứng với một thực thể vật lý xác định trong thế giới thực, có ranh giới phân định rõ ràng với môi trường nền xung quanh.

Việc định danh đối tượng được phân chia thành hai cấp độ nhận thức:

- **Đối tượng chung (General Object / Category-level):** Nhận diện một thực thể thuộc về một lớp khái niệm chung mà không phân biệt danh tính cá thể cụ thể (ví dụ: xác định một vùng ảnh chứa "nam giới", "xe ô tô" hoặc "con mèo").
- **Đối tượng cụ thể (Specific Object / Instance-level):** Định danh chính xác một thực thể duy nhất trong cơ sở dữ liệu mẫu (ví dụ: nhận diện một khuôn mặt cụ thể là "bạn An", chiếc ô tô mang biển số riêng "30F-999.99" hoặc tòa nhà cụ thể "Landmark 81").

1.9 Bản chất và thách thức của khoảng cách ngữ nghĩa (Semantic Gap)

Khoảng cách ngữ nghĩa (Semantic Gap) là sự chênh lệch căn bản giữa **cách biểu diễn dữ liệu mức thấp** của máy tính và **cách hiểu ngữ nghĩa mức cao** của con người.

Dưới góc nhìn của máy tính, hình ảnh số chỉ là một mảng dữ liệu đa chiều chứa các giá trị cường độ điểm ảnh số thô. Khi điều kiện chiếu sáng, góc chụp, khoảng cách hoặc tư thế vật thể thay đổi, toàn bộ các giá trị số trong ma trận điểm ảnh bị biến đổi hoàn toàn dù thực thể vật lý trong ảnh không thay đổi.

Ngược lại, hệ thống thị giác con người tự động trích xuất các cấu trúc bất biến, kết hợp với tri thức nền tảng về thế giới để nhận thức ngay lập tức danh tính thực thể, ngữ cảnh không gian, cảm xúc và các mối quan hệ logic phức tạp. Việc thu hẹp khoảng cách giữa tín hiệu điểm ảnh số thô và khái niệm ngữ nghĩa trừu tượng chính là bài toán trung tâm của thị giác máy tính.

1.10 Tiến trình phát triển trong việc thu hẹp khoảng cách ngữ nghĩa

Quá trình giải quyết khoảng cách ngữ nghĩa trong thị giác máy tính đã trải qua ba giai đoạn phát triển chính:

Giai đoạn trích xuất đặc trưng thủ công (Trước năm 2012): Dựa trên các thuật toán hình học và xử lý tín hiệu xác định như SIFT (Lowe, 2004), SURF (Bay et al., 2008), HOG (Dalal & Triggs, 2005) kết hợp với các bộ phân loại nông như Support Vector Machines (SVM) (Cortes & Vapnik, 1995) hoặc Random Forest (Breiman, 2001). Phương pháp này chỉ mô tả được các mẫu cục bộ đơn giản và phụ thuộc nặng nề vào kỹ nghệ thiết kế đặc trưng bằng tay, khiến khoảng cách ngữ nghĩa vẫn còn rất lớn.

Kỷ nguyên Học sâu phân cấp (Giai đoạn 2012–2020): Sự ra đời của các mạng nơ-ron tích chập sâu như AlexNet (Krizhevsky et al., 2012), VGG (Simonyan & Zisserman, 2015) và ResNet (He et al., 2016) đã mở ra cơ chế tự động học biểu diễn đặc trưng phân cấp trực tiếp từ dữ liệu thô. Các tầng nông học các đặc trưng biên nét cục bộ, trong khi các tầng sâu trừu tượng hóa thành các bộ phận và ngữ nghĩa hoàn chỉnh của đối tượng, giúp thu hẹp đáng kể khoảng cách ngữ nghĩa trong các bài toán đóng.

Kỷ nguyên Mô hình Nền tảng và Thị giác - Ngôn ngữ (Từ 2020 đến nay): Kiến trúc Vision Transformer (ViT) (Dosovitskiy et al., 2020) kết hợp với các mô hình học biểu diễn liên kết đa phương thức như CLIP (Radford et al., 2021), BLIP (Li et al., 2022), LLaVA (Liu et al., 2023) và GPT-4V (OpenAI, 2023) đã ánh xạ trực tiếp không gian ảnh và không gian ngôn ngữ tự nhiên vào cùng một không gian nhúng chung. Nhờ đó, mô hình có khả năng suy luận ngữ cảnh mở, sinh mô tả tự nhiên (Image Captioning) và trả lời câu hỏi thị giác (Visual Question Answering) một cách linh hoạt (Dai et al., 2023).

Mặc dù đạt được những tiến bộ vượt bậc, các mô hình học sâu và mô hình nền tảng hiện nay vẫn bộc lộ điểm yếu khi đối mặt với nhiễu đối kháng (adversarial perturbations) (Li et al., 2024), dễ sinh ảo giác (hallucination) trong điều kiện thiếu sáng hoặc bị che khuất nghiêm trọng (Hendrycks & Dietterich, 2019; Li et al., 2023; Guan et al., 2024), đồng thời còn hạn chế đáng kể trong khả năng suy luận quan hệ nhân quả (causal reasoning) (Zang et al., 2023).

1.11 Động lực mở rộng từ dữ liệu hình ảnh sang dữ liệu đa phương thức

Việc giới hạn mô hình trong dữ liệu hình ảnh hoặc video đơn lẻ bộc lộ nhiều điểm nghẽn nhận thức. Về mặt hình học, hình ảnh 2D là phép chiếu thu nhỏ từ thế giới 3D, làm suy giảm thông tin chiều

sâu và gây ra tính nhập nhằng về kích thước thực tế của vật thể. Hơn nữa, nhiều hiện tượng thực tế đòi hỏi sự kết hợp của các tín hiệu bổ trợ như âm thanh (tiếng va chạm cơ học, tiếng rò rỉ khí), văn bản ngữ cảnh (biển báo giao thông, tài liệu hướng dẫn) hay dữ liệu đo lường từ cảm biến gia tốc và nhiệt độ.

Dữ liệu đa phương thức mang lại cơ chế bổ trợ ngữ nghĩa hai chiều: ngôn ngữ tự nhiên cung cấp cấu trúc ngữ nghĩa trừu tượng và tri thức logic, trong khi dữ liệu thị giác cung cấp tọa độ hình học và chi tiết không gian cụ thể. Sự kết hợp này là điều kiện tiên quyết để xây dựng các hệ thống tự hành đáng tin cậy như xe tự lái (kết hợp đồng thời Camera RGB, Radar, LiDAR và bản đồ số HD) hay robot tương tác thông minh.

1.12 Phân định ranh giới giữa Đồ họa máy tính, Xử lý ảnh và Thị giác máy tính

Ba lĩnh vực Đồ họa máy tính (Computer Graphics - CG), Xử lý ảnh (Image Processing - IP) và Thị giác máy tính (Computer Vision - CV) cùng thao tác trên dữ liệu thị giác nhưng khác biệt căn bản về mục tiêu, phạm vi bài toán, phương pháp tiếp cận và bản chất chuyển đổi dữ liệu. Bảng 1 so sánh toàn diện giữa ba lĩnh vực trên 5 tiêu chí chuẩn hóa: Mục tiêu (Goal), Phạm vi (Scope), Phương pháp tiếp cận (Approach), Dữ liệu đầu vào (Input) và Dữ liệu đầu ra (Output).

Bảng 1: So sánh toàn diện giữa Computer Graphics, Image Processing và Computer Vision theo 5 tiêu chí chuẩn hóa

Tiêu chí	**Computer Graphics (CG)**	**Image Processing (IP)**	**Computer Vision (CV)**
1. Mục tiêu (Goal)	Mô phỏng thế giới thực	Nâng cao chất lượng, khôi phục ảnh suy thoái, lọc nhiễu, nén hoặc biến đổi biểu diễn dữ liệu ảnh.	Hiểu, phân tích, trích xuất cấu trúc ngữ nghĩa, tri thức và suy luận ra quyết định từ dữ liệu thị giác.
2. Phạm vi (Scope)	Không gian mô hình hình học 2D/3D trừu tượng, thực hiện chiếu phối cảnh, đổ bóng và mô phỏng vật liệu quang học.	Không gian tín hiệu pixel và tần số mức thấp, thao tác không can thiệp hay thay đổi ngữ nghĩa mức cao của đối tượng.	Không gian ngữ nghĩa mức cao, ánh xạ từ tín hiệu pixel sang biểu diễn nhận thức và quan hệ logic.
3. Phương pháp (Approach)	Mô hình hóa toán học (Polygon Mesh, Spline, NeRF, 3D Gaussian Splatting), đường ống đồ họa (Graphics Pipeline, Shaders, Ray Tracing).	Xử lý tín hiệu số 2D (lọc không gian, biến đổi Fourier/Wavelet, cân bằng lược đồ mức xám, toán tử hình thái học).	Học máy và học sâu (CNNs, Vision Transformers, Foundation Models) kết hợp hình học thị giác đa góc nhìn.
4. Đầu vào (Input)	Mô hình hình học 2D/3D (tập điểm, mesh, vertices), thuộc tính vật liệu, vị trí camera và thông số nguồn sáng.	Dữ liệu ảnh số thô, ảnh bị suy thoái do nhiễu vật lý, mờ chuyển động, thiếu sáng hoặc nén suy hao.	Hình ảnh số 2D $I \in \mathbb{R}^{H\times W\times C}$, chuỗi video $\{I_t\}$, ảnh đa phổ, đám mây điểm 3D từ môi trường thực tế.
5. Đầu ra (Output)	Hình ảnh hoặc chuỗi video được kết xuất trực quan chân thực lên màn hình hiển thị.	Hình ảnh đã qua xử lý, tăng cường hoặc khôi phục trong cùng không gian điểm ảnh.	Dữ liệu ngữ nghĩa có cấu trúc (nhãn phân loại, hộp bao, mặt nạ phân đoạn, pose 3D, quyết định hành động).
Bản chất chuyển đổi	**Dữ liệu trừu tượng → Hình ảnh**	**Hình ảnh → Hình ảnh**	**Hình ảnh → Dữ liệu ngữ nghĩa**

1.13 Khái quát các bài toán cốt lõi trong Thị giác máy tính

Các hệ thống thị giác máy tính hiện đại được cấu thành từ 7 bài toán nền tảng. Nhằm chuẩn hóa việc đánh giá và xây dựng mô hình, mỗi bài toán được phân tích có hệ thống theo 5 tiêu chí: **Mục tiêu**

(Goal), **Phạm vi (Scope)**, **Phương pháp tiếp cận (Approach)**, **Dữ liệu đầu vào (Input)** và **Dữ liệu đầu ra (Output)**.

1. Classification (Phân loại ảnh):

- **Mục tiêu (Goal):** Xác định và gán nhãn ngữ nghĩa ở mức toàn cảnh (Image-level) cho bức ảnh từ một tập danh mục lớp định trước.
- **Phạm vi (Scope):** Cấp độ toàn ảnh, tập danh mục đóng cố định ($|\mathcal{C}|$ lớp), không định vị tọa độ hay phân tách từng đối tượng riêng lẻ.
- **Phương pháp tiếp cận (Approach):** Mạng trích xuất đặc trưng sâu (CNN / ViT) kết hợp lớp Fully-Connected + Softmax, tối ưu hóa bằng hàm mất mát Cross-Entropy Loss hoặc Focal Loss.
- **Đầu vào (Input):** Hình ảnh tĩnh $I \in \mathbb{R}^{H \times W \times C}$ (với chiều cao H, chiều rộng W và C kênh màu).
- **Đầu ra (Output):** Nhãn danh mục $c \in \mathcal{C}$ hoặc vector phân phối xác suất dự đoán $\mathbf{p} = P(Y \mid I) \in \Delta^{|\mathcal{C}|-1}$.

2. Detection (Phát hiện đối tượng):

- **Mục tiêu (Goal):** Đồng thời xác định vị trí không gian (Localization) và phân loại ngữ nghĩa (Classification) cho tất cả các thực thể quan tâm xuất hiện trong ảnh.
- **Phạm vi (Scope):** Cấp độ đối tượng cụ thể (Instance-level), phát hiện đa đối tượng và đa lớp trong cùng một khung ảnh với kích thước và tỷ lệ khung hình biến thiên.
- **Phương pháp tiếp cận (Approach):** Kiến trúc Two-stage như Faster R-CNN (Ren et al., 2015), One-stage như YOLO (Redmon et al., 2016), RetinaNet (Lin et al., 2017), SSD (Liu et al., 2016) hoặc kiến trúc dựa trên Transformer như DETR (Carion et al., 2020); tối ưu đồng thời hàm mất mát phân loại (Cross-Entropy/Focal Loss) và hồi quy tọa độ hộp bao (GIoU (Rezatofighi et al., 2019), DIoU Loss (Zheng et al., 2020)) kết hợp thuật toán lọc Non-Maximum Suppression (NMS).
- **Đầu vào (Input):** Hình ảnh tĩnh hoặc từng khung hình video $I \in \mathbb{R}^{H \times W \times C}$.
- **Đầu ra (Output):** Tập hợp các hộp bao đối tượng $\mathcal{B} = \{(x_i, y_i, w_i, h_i, c_i, s_i)\}_{i=1}^{N}$, trong đó (x_i, y_i, w_i, h_i) là tọa độ tâm và kích thước khung chữ nhật bao bọc (Bounding Box), $c_i \in \mathcal{C}$ là nhãn lớp và $s_i \in [0, 1]$ là điểm số tin cậy.

3. Recognition (Nhận dạng):

- **Mục tiêu (Goal):** Định danh cụ thể một cá thể riêng biệt (Instance-level identity) trong một tập danh tính hoặc cơ sở dữ liệu mẫu đã biết (Closed-set) sau khi vùng đối tượng đã được cô lập.
- **Phạm vi (Scope):** Cấp độ cá thể riêng biệt (Fine-grained), vùng ảnh đối tượng đã được crop hoặc căn chỉnh (ROI), không gian danh tính hữu hạn định trước ($\mathcal{Y}_{\text{known}}$).
- **Phương pháp tiếp cận (Approach):** Trích xuất đặc trưng biểu diễn mức sâu kết hợp Metric Learning với góc margin lớn (CosFace, ArcFace) trên tập nhãn cố định, thực hiện so khớp 1:N với cơ sở dữ liệu mẫu (Gallery).
- **Đầu vào (Input):** Vùng ảnh chứa đối tượng đã cô lập $I_{\text{crop}} \in \mathbb{R}^{h \times w \times C}$ và cơ sở dữ liệu mẫu đã đăng ký $\mathcal{D}_{\text{gallery}}$.
- **Đầu ra (Output):** Mã định danh cá thể cụ thể (Identity ID) $y \in \mathcal{Y}_{\text{known}}$ (hoặc nhãn Unknown) kèm điểm số so khớp tương đồng.

4. Tracking (Theo dõi đối tượng):

- **Mục tiêu (Goal):** Duy trì mã định danh duy nhất (Track ID) và ước lượng quỹ đạo chuyển động không gian theo thời gian của từng đối tượng qua chuỗi khung hình video liên tiếp. Bản chất của bài toán theo dõi là sự kết hợp liên hoàn giữa Phát hiện đối tượng và So khớp liên kết dữ liệu theo thời gian (Tracking = Detection + Matching).

- **Phạm vi (Scope):** Miền không - thời gian (Spatio-temporal), liên tục trên chuỗi video thời gian thực, phạm vi tìm kiếm cục bộ quanh vị trí khung hình liền kề ($t \to t+1$).
- **Phương pháp tiếp cận (Approach):** Mô hình Tracking-by-Detection (TBD) hoặc Joint Detection & Embedding (JDE), kết hợp mô hình chuyển động động học (Kalman Filter, Optical Flow) với giải thuật tối ưu liên kết dữ liệu như thuật toán Hungarian (Kuhn, 1955) hay ByteTrack (Zhang et al., 2022) dựa trên chỉ số IoU và độ tương đồng Cosine đặc trưng.
- **Đầu vào (Input):** Chuỗi khung hình video liên tục $\{I_t\}_{t=1}^{T}$ với $I_t \in \mathbb{R}^{H \times W \times C}$.
- **Đầu ra (Output):** Tập các vết quỹ đạo không gian - thời gian $\mathcal{T} = \{(\text{ID}_i, t, x_{i,t}, y_{i,t}, w_{i,t}, h_{i,t})\}$, đảm bảo tính nhất quán định danh của từng cá thể qua trục thời gian t.

5. Retrieval (Truy vấn hình ảnh):

- **Mục tiêu (Goal):** Tìm kiếm và xếp hạng các hình ảnh có độ tương đồng nội dung cao nhất với ảnh truy vấn từ một kho cơ sở dữ liệu lớn ở môi trường mở (Open-set).
- **Phạm vi (Scope):** Cấp độ toàn cục trên kho dữ liệu quy mô lớn $\mathcal{D}$, không gian mở đối với các thực thể chưa từng thấy khi huấn luyện, các mẫu dữ liệu ảnh tĩnh độc lập phi thời gian.
- **Phương pháp tiếp cận (Approach):** Học không gian nhúng biểu diễn sâu (Deep Metric Learning / Contrastive Learning) với Triplet Loss hoặc InfoNCE Loss; ánh xạ ảnh thành vector nhúng $\mathbf{v} = f_\theta(I) \in \mathbb{R}^d$, lập chỉ mục vector và tìm kiếm lân cận gần nhất xấp xỉ (Approximate Nearest Neighbor - ANN như FAISS, HNSW).
- **Đầu vào (Input):** Ảnh truy vấn (Query Image) $I_q \in \mathbb{R}^{H \times W \times C}$ và kho cơ sở dữ liệu ảnh mẫu $\mathcal{D} = \{I_1, I_2, \ldots, I_M\}$.
- **Đầu ra (Output):** Danh sách xếp hạng thứ tự top-K ảnh $\{I_{\pi(1)}, I_{\pi(2)}, \ldots, I_{\pi(K)}\}$ có khoảng cách biểu diễn nhỏ nhất trong không gian nhúng kèm điểm số tương đồng Cosine.

6. Counting (Đếm đối tượng):

- **Mục tiêu (Goal):** Ước lượng tổng số lượng thực thể xuất hiện trong khung cảnh, đặc biệt hiệu quả trong các tình huống có mật độ cực cao hoặc che khuất nghiêm trọng.
- **Phạm vi (Scope):** Cấp độ khung cảnh mật độ cao (đám đông, vi sinh vật, đàn gia súc), chấp nhận hiện tượng che khuất chồng chéo sâu (Severe Occlusion).
- **Phương pháp tiếp cận (Approach):** Hồi quy trường mật độ liên tục (Density Map Estimation) qua mạng nơ-ron tích chập hoàn toàn (FCNs) hoặc Transformer như CSRNet (Li et al., 2018) hay DM-Count (Wang et al., 2020) với hàm mất mát MSE hoặc Bayesian Loss dựa trên nhãn điểm tâm (Dot annotation) được lọc Gaussian; tránh hoàn toàn bước phân tách hộp bao rời rạc và lọc NMS.
- **Đầu vào (Input):** Hình ảnh tĩnh $I \in \mathbb{R}^{H \times W \times C}$ (kèm nhãn tọa độ điểm chấm (x_p, y_p) trong pha huấn luyện).
- **Đầu ra (Output):** Bản đồ mật độ liên tục $D \in \mathbb{R}^{H \times W}$, trong đó tổng tích phân $\hat{N} = \sum_{x,y} D(x,y)$ xấp xỉ tổng số đối tượng (hoặc giá trị số thực ước tính $\hat{N} \in \mathbb{R}^+$).

7. Generating (Sinh dữ liệu thị giác):

- **Mục tiêu (Goal):** Khởi tạo hình ảnh hoặc chuỗi video mới hoàn chỉnh, mô phỏng đúng phân phối dữ liệu thị giác thực tế $P(X)$ hoặc sinh có điều kiện theo yêu cầu người dùng.
- **Phạm vi (Scope):** Toàn bộ không gian phân phối xác suất dữ liệu cao chiều, từ sinh vô điều kiện đến sinh có điều kiện đa phương thức (Text-to-Image, Image-to-Image, Inpainting, ControlNet).
- **Phương pháp tiếp cận (Approach):** Mô hình xác suất tạo sinh sâu (GANs với Minimax Adversarial Loss, VAEs với ELBO, Diffusion Models / Flow Matching với Denoising Score Matching và U-Net/DiT).

- **Đầu vào (Input):** Vector nhiễu ngẫu nhiên $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I})$ trong không gian tiềm ẩn, kèm theo điều kiện dẫn đường tùy chọn (mô tả văn bản $\mathbf{c}_{\text{text}}$, ảnh điều kiện I_{cond}, bản đồ bố cục Canny/Pose).
- **Đầu ra (Output):** Hình ảnh hoặc chuỗi video tổng hợp mới $\hat{I} \in \mathbb{R}^{H \times W \times C}$ có độ chân thực cao và thỏa mãn các ràng buộc ngữ nghĩa đầu vào.

Bảng 2 tóm tắt ma trận so sánh 7 bài toán cốt lõi của Thị giác máy tính theo đúng 5 tiêu chí chuẩn hóa.

Bảng 2: Ma trận tổng hợp so sánh 7 bài toán cốt lõi trong Thị giác máy tính theo 5 tiêu chí

Bài toán	**Mục tiêu (Goal)**	**Phạm vi (Scope)**	**Phương pháp (Approach)**	**Đầu vào (Input)**	**Đầu ra (Output)**
Classification	Gán nhãn ngữ nghĩa toàn cảnh	Toàn ảnh, tập đóng $\mathcal{C}$ lớp	CNN / ViT + Softmax (Cross-Entropy Loss)	Ảnh tĩnh $I \in \mathbb{R}^{H \times W \times C}$	Nhãn $c \in \mathcal{C}$, phân phối $\mathbf{p}$
Detection	Định vị & phân loại đối tượng	Đối tượng (Instance), đa lớp	Two/One-stage, DETR, Box Loss + NMS	Ảnh tĩnh / Khung video I	Hộp bao $\mathcal{B} = \{(x, y, w, h, c, s)\}$
Recognition	Định danh cá thể cụ thể	Cá thể (Instance), tập đóng	Deep Embedding + ArcFace / Softmax	Ảnh crop $I_{\text{crop}} + \mathcal{D}_{\text{gallery}}$	Identity ID $y \in \mathcal{Y}_{\text{known}}$
Tracking	Duy trì ID & quỹ đạo theo thời gian	Không - thời gian, video liên tục	Tracking-by-Detection + Kalman + ByteTrack	Chuỗi video $\{I_t\}_{t=1}^{T}$	Quỹ đạo $\mathcal{T} = \{(\text{ID}_i, t, \mathbf{b}_{i,t})\}$
Retrieval	Tìm ảnh tương đồng ngữ nghĩa	Toàn cục kho ảnh, tập mở (Open-set)	Metric Learning (InfoNCE, Triplet) + ANN	Ảnh truy vấn $I_q + \mathcal{D}$	Ranked List $\{I_{\pi(k)}\}$
Counting	Ước lượng số lượng thực thể	Mật độ cao, chịu che khuất nặng	Hồi quy bản đồ mật độ (CSRNet) + Density Loss	Ảnh tĩnh $I \in \mathbb{R}^{H \times W \times C}$	Bản đồ mật độ $D \to \hat{N} = \sum D$
Generating	Khởi tạo nội dung thị giác mới	Không gian phân phối dữ liệu $P(X)$	Diffusion Models, GANs, VAEs, Flow Matching	Nhiễu $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I}) +$ Condition	Ảnh/video mới $\hat{I}$

1.14 So sánh bài toán Nhận dạng (Recognition) và Truy vấn ảnh (Image Retrieval)

Mặc dù đều phục vụ mục đích xác định sự tương đồng của đối tượng thị giác, Nhận dạng (Recognition) và Truy vấn ảnh (Image Retrieval) khác biệt căn bản về mục tiêu, không gian bài toán, cơ chế tối ưu hóa hàm mất mát, dữ liệu đầu vào và dạng thức đầu ra (Bảng 3).

1.15 So sánh bài toán Truy vấn ảnh (Retrieval) và Theo dõi đối tượng (Tracking)

Sự khác biệt cốt lõi giữa Truy vấn ảnh (Retrieval) và Theo dõi đối tượng (Tracking) bắt nguồn từ yếu tố phụ thuộc thời gian, miền không gian tìm kiếm, phương pháp kết hợp mô hình động học và dạng thức đầu ra (Bảng 4):

1.16 So sánh bài toán Đếm đối tượng (Counting) và Phát hiện đối tượng (Object Detection)

Trong các khung cảnh thông thường với mật độ thưa, bài toán đếm có thể giải quyết gián tiếp thông qua việc phát hiện từng đối tượng riêng lẻ. Tuy nhiên, khi mật độ tăng cao và xuất hiện hiện tượng che khuất nghiêm trọng, hai phương pháp này thể hiện sự khác biệt rõ rệt trên cả 5 tiêu chí (Bảng 5):

1.17 Mô hình Tạo sinh (Generative) và tương quan với các tác vụ Phân tích (Discriminative)

Các bài toán trong học máy và thị giác máy tính được phân chia thành hai trường phái nền tảng dựa trên mục tiêu mô hình hóa phân phối xác suất, phạm vi biến đổi không gian dữ liệu và cách thức tối ưu hóa (Bảng 6):

Bảng 3: So sánh toàn diện giữa bài toán Recognition và Image Retrieval theo 5 tiêu chí

Tiêu chí	Nhận dạng (Recognition)	Truy vấn hình ảnh (Image Retrieval)
1. Mục tiêu (Goal)	Định danh chính xác một cá thể cụ thể (Instance Identity) thuộc về một danh tính đã đăng ký trước trong hệ thống.	Tìm kiếm và xếp hạng các hình ảnh có độ tương đồng ngữ nghĩa/nội dung cao nhất với ảnh truy vấn từ một kho dữ liệu lớn.
2. Phạm vi (Scope)	Tập đóng (Closed-set): số lượng lớp và danh tính được cố định trước trong quá trình huấn luyện; đối tượng thường là vùng ảnh đã được cô lập (Cropped/Aligned ROI).	Tập mở (Open-set): tìm kiếm các thực thể và mẫu chưa từng xuất hiện trong tập huấn luyện; phạm vi tìm kiếm toàn cục trên cơ sở dữ liệu quy mô lớn $\mathcal{D}$.
3. Phương pháp (Approach)	Học các siêu phẳng phân tách ranh giới giữa các lớp xác định bằng Softmax hoặc Margin Loss (ArcFace, CosFace); suy luận trực tiếp bằng $\arg\max$ xác suất hoặc so khớp ngưỡng với Gallery mẫu cố định.	Học không gian nhúng biểu diễn (Deep Metric Learning / Contrastive Learning) với Triplet Loss, InfoNCE Loss để tối ưu khoảng cách biểu diễn; suy luận bằng trích xuất embedding và thuật toán tìm kiếm lân cận gần nhất (k-NN, ANN, FAISS).
4. Đầu vào (Input)	Vùng ảnh chứa đối tượng đã cô lập $I_{\text{crop}} \in \mathbb{R}^{h \times w \times C}$ và cơ sở dữ liệu mẫu đã đăng ký $\mathcal{D}_{\text{gallery}}$.	Ảnh truy vấn (Query Image) $I_q \in \mathbb{R}^{H \times W \times C}$ và kho cơ sở dữ liệu ảnh mẫu quy mô lớn $\mathcal{D} = \{I_1, I_2, \ldots, I_M\}$.
5. Đầu ra (Output)	Mã định danh cá thể cụ thể (Identity ID) $y \in \mathcal{Y}_{\text{known}}$ (hoặc nhãn Unknown) kèm xác suất hoặc điểm số tin cậy.	Danh sách có thứ tự xếp hạng (Ranked List) top-K hình ảnh tương đồng nhất $\{I_{\pi(1)}, \ldots, I_{\pi(K)}\}$ kèm điểm số khoảng cách.

Bảng 4: So sánh toàn diện giữa bài toán Image Retrieval và Object Tracking theo 5 tiêu chí

Tiêu chí	Truy vấn hình ảnh (Retrieval)	Theo dõi đối tượng (Tracking)
1. Mục tiêu (Goal)	Tìm kiếm và xếp hạng các hình ảnh tương đồng nhất với ảnh mẫu trong kho dữ liệu tĩnh.	Duy trì định danh duy nhất (Track ID) và ước lượng quỹ đạo chuyển động không gian theo thời gian của đối tượng qua chuỗi video.
2. Phạm vi (Scope)	Không gian toàn cục tĩnh: các mẫu dữ liệu độc lập, phi thời gian, không có liên kết vật lý thời gian.	Không - thời gian cục bộ: chuỗi video thời gian thực liên tục; tìm kiếm trong lân cận không gian dự đoán từ khung hình liền kề ($t \to t+1$).
3. Phương pháp (Approach)	Sử dụng thuần túy mô hình đặc trưng ngoại hình tĩnh kết hợp cấu trúc dữ liệu chỉ mục vector như IVF-PQ (Jégou et al., 2011) hay HNSW.	Kết hợp mô hình ngoại hình và mô hình chuyển động động học (Kalman Filter, Optical Flow) cùng giải thuật tối ưu phân phối liên kết dữ liệu (Hungarian Matching (Kuhn, 1955), ByteTrack (Zhang et al., 2022)).
4. Đầu vào (Input)	Ảnh truy vấn I_q và kho cơ sở dữ liệu ảnh mẫu độc lập $\mathcal{D} = \{I_1, \ldots, I_M\}$.	Chuỗi khung hình video liên tục $\{I_t\}_{t=1}^{T}$ có tính tương quan thời gian cao theo tốc độ khung hình ($I_t \in \mathbb{R}^{H \times W \times C}$).
5. Đầu ra (Output)	Danh sách các hình ảnh xếp hạng theo độ tương đồng $\{I_{\pi(1)}, \ldots, I_{\pi(K)}\}$.	Tập hợp các vết quỹ đạo không gian - thời gian $\mathcal{T} = \{(\text{Track ID}_i, t, x_{i,t}, y_{i,t}, w_{i,t}, h_{i,t})\}$.

Bảng 5: So sánh toàn diện giữa bài toán Object Detection và Crowd Counting theo 5 tiêu chí

Tiêu chí	Phát hiện đối tượng (Detection)	Đếm đối tượng (Counting)
1. Mục tiêu (Goal)	Đồng thời định vị ranh giới không gian (Bounding Box) và phân loại ngữ nghĩa cho từng cá thể độc lập.	Ước lượng tổng số lượng thực thể xuất hiện trong khung cảnh, tập trung vào mật độ tổng thể thay vì ranh giới từng cá thể.
2. Phạm vi (Scope)	Thích hợp cho khung cảnh thưa đến trung bình, đối tượng có ranh giới rõ ràng; suy giảm độ chính xác nghiêm trọng khi mật độ cực cao và che khuất chồng chéo sâu.	Chuyên biệt hóa cho khung cảnh mật độ từ trung bình đến cực dày đặc (đám đông, vi sinh vật, xe cộ), bền vững trước hiện tượng che khuất nghiêm trọng.
3. Phương pháp (Approach)	Hồi quy hộp bao rời rạc và phân loại nhãn (Two-stage/One-stage/DETR) với Cross-Entropy + GIoU Loss, lọc Non-Maximum Suppression (NMS); yêu cầu nhãn hộp bao chi tiết (x, y, w, h).	Hồi quy trường mật độ liên tục (Density Map Estimation) qua FCN/Transformer với hàm mất mát MSE hoặc Bayesian Loss; chỉ yêu cầu nhãn điểm tâm (Dot annotation) Gaussian hóa; không dùng NMS.
4. Đầu vào (Input)	Hình ảnh tĩnh hoặc khung hình video $I \in \mathbb{R}^{H\times W\times C}$ (kèm nhãn hộp bao chi tiết trong pha huấn luyện).	Hình ảnh tĩnh hoặc chuỗi khung hình $I \in \mathbb{R}^{H\times W\times C}$ (kèm nhãn tọa độ điểm chấm (x_p, y_p) trong pha huấn luyện).
5. Đầu ra (Output)	Tập hợp các hộp bao rời rạc $\mathcal{B} = \{(x_i, y_i, w_i, h_i, c_i, s_i)\}_{i=1}^{N} \implies \hat{N} = \lvert\mathcal{B}\rvert$.	Bản đồ phân phối mật độ liên tục $D \in \mathbb{R}^{H\times W} \implies \hat{N} = \sum_{x,y} D(x, y)$ (hoặc trực tiếp giá trị vô hướng $\hat{N}$).

2 Tuần 2: Trí tuệ Nhân tạo, Học máy & Học sâu trong Khoa học Dữ liệu Thị giác

2.1 Bản chất của Trí tuệ Tự nhiên, Trí tuệ Nhân tạo và Khái niệm Thông minh

Trong khoa học nhận thức và khoa học máy tính, việc phân định rõ các dạng thức trí tuệ là tiền đề quan trọng để xây dựng và phát triển các hệ thống tính toán:

Trí tuệ Tự nhiên (Natural Intelligence - NI): Là năng lực sinh học bẩm sinh của con người và các loài sinh vật bậc cao, được tôi luyện qua hàng triệu năm tiến hóa. Trí tuệ tự nhiên tích hợp toàn diện các phương thức: thu nhận cảm giác đa giác quan, tự ý thức (Self-awareness), tư duy trừu tượng, sáng tạo nghệ thuật, suy luận quan hệ nhân quả và khả năng thích ứng linh hoạt trước những biến động bất định của môi trường sống, đi kèm với đời sống cảm xúc và các chuẩn mực đạo đức xã hội.

Trí tuệ Nhân tạo (Artificial Intelligence - AI): Là một phân ngành của khoa học máy tính nghiên cứu các nguyên lý toán học, cấu trúc dữ liệu và giải thuật nhằm kiến tạo các hệ thống tính toán (phần mềm và phần cứng) có khả năng mô phỏng các khía cạnh hành vi thông minh của con người. Các hành vi này bao gồm năng lực học hỏi từ dữ liệu (Learning), suy luận logic (Reasoning), nhận thức thị giác (Visual Perception), xử lý ngôn ngữ tự nhiên (NLP) và lập kế hoạch ra quyết định (Decision Making).

Bảng 7 đối chiếu các khía cạnh nền tảng giữa Trí tuệ Tự nhiên và Trí tuệ Nhân tạo.

Xét về mặt vận hành, mọi hệ thống thông minh đều thực thi một vòng lặp nhận thức khép kín gồm 3 giai đoạn liên hoàn:

1. **Giai đoạn 1: Nhận biết (Perception):** Tiếp nhận các kích thích và tín hiệu vật lý từ môi trường bên ngoài. Ở con người, đó là hệ thống thụ cảm đa giác quan (thị giác, thính giác, xúc giác) với cơ chế chú ý tự nhiên chọn lọc thông tin. Ở AI, đó là các cảm biến quang học, LiDAR hoặc micro thu nhận sóng vật lý và chuyển đổi thành mảng ma trận điểm ảnh số thô $I \in \mathbb{R}^{H\times W\times C}$.
2. **Giai đoạn 2: Hiểu (Understanding / Recognition):** Chuyển hóa dữ liệu thô thành ngữ nghĩa, cấu trúc tri thức và mô hình hóa thế giới. Con người hiểu sâu sắc về chức năng, bối cảnh văn hóa và quan hệ nhân quả của thực thể. Trong khi đó, hệ thống AI thực hiện trích

Bảng 6: So sánh toàn diện giữa mô hình Tạo sinh (Generative) và các tác vụ Phân tích (Discriminative) theo 5 tiêu chí

Tiêu chí	**Tác vụ Phân tích (Discriminative Tasks)**	**Tác vụ Tạo sinh (Generative Tasks)**
1. Mục tiêu (Goal)	Trích xuất thông tin ngữ nghĩa, định vị, phân loại hoặc đưa ra quyết định từ dữ liệu thị giác đã có (nhận thức thế giới quan).	Học phân phối dữ liệu thị giác thực tế $P(X)$ để tổng hợp, khởi tạo hoặc tái tạo nội dung hình ảnh/video mới chân thực (kiến tạo nội dung).
2. Phạm vi (Scope)	Không gian phân loại hoặc hồi quy có giám sát; ánh xạ thu hẹp từ không gian ảnh cao chiều về không gian nhãn/tọa độ/vector tóm lược ($f : \mathcal{X} \to \mathcal{Y}$).	Toàn bộ không gian phân phối dữ liệu thị giác cao chiều $P(X)$ hoặc $P(X \mid Y)$; bao gồm sinh vô điều kiện, có điều kiện (Text-to-Image, ControlNet) và mô hình hóa không gian tiềm ẩn liên tục.
3. Phương pháp (Approach)	Học xác suất hậu nghiệm $P(Y \mid X)$ (ResNet (He et al., 2016), ViT (Dosovitskiy et al., 2020), YOLO (Redmon et al., 2016), DETR (Carion et al., 2020)); tối ưu hóa ranh giới phân tách lớp bằng Cross-Entropy, Focal Loss (Lin et al., 2017), GIoU Loss (Rezatofighi et al., 2019).	Học phân phối thực $P(X)$ hoặc đồng thời $P(X, Y)$ (GANs (Goodfellow et al., 2014), VAEs (Kingma & Welling, 2014), Diffusion Models (Ho et al., 2020), Flow Matching (Lipman et al., 2023), DiT (Peebles & Xie, 2023)); tối ưu hóa phân phối bằng Minimax Adversarial Loss, ELBO, Denoising Score Matching MSE.
4. Đầu vào (Input)	Hình ảnh hoặc video thô $I \in \mathbb{R}^{H \times W \times C}$ thu nhận từ môi trường thực tế.	Vector nhiễu ngẫu nhiên $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I})$ từ không gian tiềm ẩn kèm tín hiệu dẫn đường điều kiện (văn bản $\mathbf{c}_{\text{text}}$, ảnh bố cục, pose, cạnh nét).
5. Đầu ra (Output)	Dữ liệu ngữ nghĩa có cấu trúc (nhãn phân loại, hộp bao, mặt nạ phân đoạn, vector nhúng, số đếm, vết quỹ đạo).	Hình ảnh hoặc chuỗi video tổng hợp mới hoàn chỉnh $\hat{I} \in \mathbb{R}^{H \times W \times C}$ có độ phân giải cao và chân thực.

xuất đặc trưng phân cấp, ánh xạ xác suất lớp $P(Y \mid X)$, định vị hộp bao và xây dựng đồ thị quan hệ cảnh (Scene Graph).

3. **Giai đoạn 3: Thích nghi và Hành động (Action / Adaptation):** Ra quyết định, lập kế hoạch và thực thi hành động để tác động trở lại môi trường hoặc đạt tới mục tiêu tối ưu. Con người hành động dựa trên ý chí, cảm xúc và khả năng ứng biến linh hoạt trước tình huống mới. AI hành động thông qua cơ cấu chấp hành (bộ điều khiển xe tự lái, tín hiệu điều khiển relay) hoặc đề xuất giải pháp, đồng thời thích nghi bằng cách cập nhật trọng số mô hình qua giải thuật học máy.

Từ tiến trình nhận thức trên, bản chất của khái niệm **Thông minh (Intelligence)** được xác lập dựa trên hai trụ cột cốt lõi:

- *Năng lực nhận biết và mô hình hóa vấn đề nhanh chóng:* Khả năng trích xuất thông tin cấu trúc và nắm bắt quy luật tiềm ẩn từ môi trường dữ liệu phức tạp, không đầy đủ hoặc có độ nhiễu cao.
- *Năng lực thích ứng linh hoạt (Adaptability):* Khả năng tự điều chỉnh hành vi, cập nhật trọng số tri thức và đưa ra quyết định tối ưu khi môi trường xung quanh hoặc phân phối dữ liệu đầu vào biến đổi.

2.2 Tác động của Trí tuệ Nhân tạo đối với sự phát triển của Trí tuệ Tự nhiên

Việc ứng dụng Trí tuệ Nhân tạo vào đời sống xã hội và nghiên cứu khoa học mang lại tác động biện chứng hai chiều đối với sự phát triển của trí tuệ con người:

1. Khía cạnh tích cực: Khuếch đại năng lực nhận thức (Cognitive Augmentation):

Bảng 7: Đối chiếu nền tảng giữa Trí tuệ Tự nhiên (NI) và Trí tuệ Nhân tạo (AI)

Tiêu chí đối chiếu	Trí tuệ Tự nhiên (NI)	Trí tuệ Nhân tạo (AI)
1. Cơ chất vật lý	Mạng nơ-ron sinh học hữu cơ (~ 86 tỷ nơ-ron, 10^{14} khớp thần kinh synapse) hoạt động thông qua tín hiệu điện sinh học và hóa sinh.	Phần cứng bán dẫn vô cơ (Silicon, GPU/TPU) xử lý thông tin thông qua các xung điện nhị phân (bit 0 và 1).
2. Nguồn gốc & Mục đích	Hình thành qua quá trình chọn lọc tự nhiên và tiến hóa sinh học; mục đích cốt lõi là sinh tồn, thích nghi sinh thái và duy trì nòi giống.	Do con người thiết kế và lập trình; mục đích là công cụ tự động hóa, giải quyết bài toán kỹ thuật và phục vụ lợi ích kinh tế - xã hội.
3. Cơ chế học tập	Học hiệu quả từ số ít mẫu (Few-shot), tiếp thu qua trải nghiệm tương tác với thế giới thực và duy trì quá trình học liên tục suốt đời.	Dựa trên tối ưu hóa thống kê trên các tập dữ liệu số khổng lồ; dễ gặp hiện tượng quên tri thức cũ (Catastrophic Forgetting) khi đổi miền dữ liệu.
4. Bản chất tư duy	Suy luận quan hệ nhân quả (Causal Reasoning), trực giác trừu tượng hóa và hiểu rõ bản chất nguyên nhân (**"Tại sao"**).	So khớp mẫu và tính toán tương quan xác suất ($P(Y \mid X)$), xấp xỉ hàm toán học trả lời câu hỏi dự đoán (**"Cái gì"**).
5. Ý thức & Cảm xúc	Có ý thức tự thân, cảm xúc thực và gắn liền với sự thấu cảm cùng trách nhiệm đạo đức.	Hoạt động dựa trên xử lý tín hiệu và tính toán số học thuần túy; phản hồi cảm xúc chỉ là kết quả mô phỏng bề mặt qua văn bản hoặc hình ảnh.
6. Hiệu suất năng lượng	Tối ưu hóa cao: toàn bộ não bộ con người chỉ tiêu thụ mức công suất sinh học ước tính khoảng 20 W.	Tiêu hao năng lượng lớn: các trung tâm dữ liệu huấn luyện mô hình nền tảng tiêu thụ từ hàng kilowatt đến hàng megawatt điện.
7. Phạm vi năng lực	Trí tuệ tổng quát (General Intelligence): con người có thể học đồng thời nhiều kỹ năng khác nhau và chuyển giao tri thức linh hoạt.	Trí tuệ chuyên biệt (Narrow AI): thực thi vượt trội trong tác vụ hẹp được huấn luyện (cờ vây, nhận diện khuôn mặt) nhưng khó tổng quát hóa sang miền mới.

- *Giải phóng con người khỏi các tác vụ tính toán lặp lại:* AI đảm nhận các công việc tốn thời gian nhưng mang tính quy chuẩn cao (như thống kê dữ liệu, rà soát văn bản, phân loại ảnh hàng loạt), tạo điều kiện cho con người tập trung vào tư duy sáng tạo, phản biện và hoạch định chiến lược.

- *Mở rộng ranh giới khám phá khoa học:* AI hỗ trợ giải mã các cấu trúc quy luật phức tạp mà trực giác sinh học khó bao quát, điển hình như việc dự đoán cấu trúc protein 3D và các tương tác phân tử sinh học với AlphaFold (Jumper et al., 2021; Abramson et al., 2024), tìm kiếm thiên thể trong thiên văn học hay chẩn đoán sớm tổn thương tế bào y sinh.

2. Khía cạnh tiêu cực: Nguy cơ phụ thuộc và suy giảm nhận thức (Cognitive Offloading):

- *Suy giảm phản xạ tư duy độc lập:* Sự phụ thuộc quá mức vào các đề xuất tự động của thuật toán (Automation Bias) có thể làm suy yếu khả năng tính toán độc lập, lập luận logic nền tảng và làm giảm sút năng lực ghi nhớ làm việc (Working Memory).

- *Hiện tượng định kiến trong bong bóng thông tin (Echo Chambers):* Các thuật toán tối ưu hóa tương tác có thể cô lập người dùng trong các luồng quan điểm một chiều, làm suy giảm tính đa dạng và sự thấu cảm trong nhận thức xã hội.

Như vậy, việc ứng dụng AI không tất yếu dẫn đến sự phát triển vượt bậc hay làm thoái hóa trí tuệ tự nhiên. Hệ quả thực tế phụ thuộc vào phương thức con người định vị công nghệ: nếu xem AI là cộng sự khuếch đại nhận thức (Co-pilot) để nâng tầm tư duy thì trí tuệ tự nhiên sẽ tiến bộ; ngược lại nếu sử dụng công nghệ như một giải pháp thay thế thụ động hoàn toàn thì năng lực tư duy tự thân sẽ suy giảm.

2.3 Phân định bản chất giữa Thông minh (Intelligence) và Thông tuệ (Wisdom)

Trong khoa học nhận thức và triết học, "Thông minh" và "Thông tuệ" đại diện cho hai cấp độ nhận thức hoàn toàn khác biệt (Bảng 8).

Bảng 8: Đối chiếu toàn diện giữa khái niệm Thông minh (Intelligence) và Thông tuệ (Wisdom)

Tiêu chí	Thông minh (Intelligence)	Thông tuệ / Trí huệ (Wisdom)
Định nghĩa cốt lõi	Năng lực giải quyết bài toán và tối ưu hóa mục tiêu: thực thi công việc một cách hiệu quả và chính xác nhất (*Doing things right*).	Năng lực định hướng giá trị và mục đích: lựa chọn đúng mục tiêu có ý nghĩa nhân văn để thực hiện (*Doing the right things*).
Đối tượng xử lý	Dữ liệu số, cấu trúc thông tin, quy tắc logic và các không gian trạng thái toán học.	Ý nghĩa xã hội, chuẩn mực đạo đức, hạnh phúc con người và tính bền vững lâu dài.
Động lực vận hành	Tối ưu hóa hàm mục tiêu (cực tiểu hóa tổn thất hoặc cực đại hóa phần thưởng) dựa trên dữ liệu thống kê quá khứ.	Cân bằng hài hòa giữa lợi ích cá nhân và cộng đồng, gắn liền với lòng trắc ẩn (Compassion) và sự thấu cảm.
Khả năng hiện thực	Máy tính và AI có thể đạt trình độ vượt trội (Super-human) trong các tác vụ tính toán chuyên biệt.	Là đặc tính độc bản của nhận thức sinh học và trải nghiệm sống; AI hiện tại chưa thể có trí tuệ thông tuệ tự thân.

2.4 Giải thích Luận điểm: "Thông minh là Khả năng Thích ứng với sự Thay đổi"

Nhà vật lý lý thuyết Stephen Hawking từng đưa ra định nghĩa nổi tiếng về bản chất của trí tuệ:

> *"Intelligence is the ability to adapt to change."* (*Thông minh là khả năng thích ứng với sự thay đổi*.)

Luận điểm này phản ánh nguyên lý cốt lõi của tính thông minh trong cả tiến hóa sinh học lẫn khoa học máy tính:

1. Góc độ Trí tuệ Sinh học và Tâm lý học Nhận thức: Môi trường tự nhiên luôn biến động không ngừng. Một sinh vật chỉ duy trì các phản xạ cố định sẽ nhanh chóng bị đào thải khi hoàn cảnh sống thay đổi. Nhà tâm lý học Jean Piaget (Piaget, 1950) chỉ ra rằng sự phát triển nhận thức thực chất là quá trình thích ứng liên tục thông qua hai cơ chế bổ trợ: **Đồng hóa (Assimilation)**, tức quá trình tiếp nhận thông tin mới vào cấu trúc tri thức sẵn có; và **Điều ứng (Accommodation)**, tức việc tái cấu trúc mô hình tư duy để tương thích với thực tế biến đổi. Khả năng điều chỉnh linh hoạt giữa hai cơ chế này giúp sinh vật thích nghi và tồn tại.

2. Góc độ Học máy và Thị giác Máy tính: Trong kỹ thuật học máy, một mô hình chỉ ghi nhớ máy móc các mẫu trong tập huấn luyện (hiện tượng Overfitting) không thể coi là thông minh. Tính thông minh của hệ thống AI được định lượng bằng năng lực thích ứng với các biến số mới:

- *Khả năng khái quát hóa và xử lý dữ liệu lệch phân phối (Out-of-Distribution - OOD):* Mô hình phải nhận diện chính xác đối tượng khi điều kiện chiếu sáng, góc quan sát hoặc môi trường bị biến đổi so với tập dữ liệu huấn luyện ban đầu.
- *Thích ứng miền (Domain Adaptation) và Học chuyển giao (Transfer Learning):* Tận dụng tri thức đã học từ miền nguồn (như dữ liệu ảnh mô phỏng đồ họa 3D) để thích ứng nhanh với miền đích thực tế (ảnh camera ngoài đời thực) với lượng dữ liệu gán nhãn tối thiểu.
- *Học tăng cường thích ứng (Reinforcement Learning):* Tác tử tự động điều chỉnh chính sách hành động $\pi(a \mid s)$ dựa trên tín hiệu phản hồi phần thưởng từ môi trường động.
- *Học trong ngữ cảnh (In-Context Learning):* Khả năng của các Mô hình Nền tảng trong việc thực thi tác vụ mới chỉ qua một vài câu gợi ý hướng dẫn (Prompt) hoặc vài mẫu thị giác mà không cần huấn luyện lại toàn bộ mạng.

2.5 Bản chất của Học máy: Phân tích tư tưởng Arthur Samuel (1959)

Năm 1959, Arthur Samuel đã đưa ra định nghĩa nền tảng về Học máy:

> *"Machine Learning: Field of study that gives computers the ability to learn without being explicitly programmed."*

Luận điểm trên phân định ranh giới giữa hai hệ hình tính toán:

- **Lập trình truyền thống (Rule-based Systems):** Lập trình viên phải hiểu rõ toàn bộ logic nghiệp vụ, sau đó viết thủ công từng dòng lệnh điều kiện (`if-else`) và các công thức giải tích. Mô hình vận hành theo sơ đồ:

  $$\text{Dữ liệu đầu vào (Data)} + \text{Quy tắc lập trình (Rules)} \longrightarrow \text{Kết quả đầu ra (Output)}$$

  Cách tiếp cận này gặp rào cản lớn trước các bài toán thị giác phi cấu trúc, bởi con người không thể lập trình tường minh hàng triệu điều kiện cho mọi biến thiên cường độ pixel của một bức ảnh.
- **Hệ hình Học máy (Learning-based Systems):** Thay vì lập trình quy tắc, kỹ sư thiết kế một kiến trúc mô hình tham số hóa $f_\theta(x)$ và định nghĩa một hàm mục tiêu (Loss Function) $\mathcal{L}$. Thuật toán sẽ tự động tối ưu hóa tập tham số θ dựa trên dữ liệu mẫu:

  $$\text{Dữ liệu đầu vào (Data)} + \text{Dữ liệu nhãn/Mục tiêu (Output)} \longrightarrow \text{Mô hình đã học } (\theta^*)$$

2.6 Định nghĩa Hình thức về Học máy theo Tom Mitchell (1997)

Năm 1997, Tom Mitchell đã chuẩn hóa lý thuyết học máy bằng định nghĩa toán học chặt chẽ:

> *"A computer program is said to learn from experience $\mathcal{E}$ with respect to some class of tasks $\mathcal{T}$ and performance measure $\mathcal{P}$, if its performance at tasks in $\mathcal{T}$, as measured by $\mathcal{P}$, improves with experience $\mathcal{E}$."*

Định nghĩa này cấu thành từ bộ ba $(\mathcal{T}, \mathcal{E}, \mathcal{P})$:

- **Nhiệm vụ $\mathcal{T}$ (Task):** Bài toán mục tiêu mà hệ thống cần thực hiện. Ví dụ trong thị giác máy tính: Phát hiện vị trí các khuyết tật trên bề mặt vi mạch $I \in \mathbb{R}^{H \times W \times C}$.
- **Trải nghiệm $\mathcal{E}$ (Experience):** Tập hợp dữ liệu lịch sử hoặc các tương tác mà mô hình được tiếp cận. Ví dụ: Tập dữ liệu $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}$ gồm $100,000$ hình ảnh vi mạch được gán nhãn vị trí lỗi chuẩn bởi chuyên gia kiểm thử.
- **Độ đo hiệu năng $\mathcal{P}$ (Performance Measure):** Thước đo định lượng toán học dùng để đánh giá chất lượng thực thi tác vụ. Ví dụ: Chỉ số độ chính xác trung bình mAP@0.5 trên tập kiểm thử độc lập $\mathcal{D}_{\text{test}}$.

Một thuật toán được xác nhận là đang học khi chất lượng thực thi tăng đơn điệu theo lượng dữ liệu trải nghiệm:

$$\frac{\partial \mathcal{P}(\mathcal{T})}{\partial \mathcal{E}} > 0 \quad \text{hoặc} \quad \lim_{|\mathcal{E}| \to \infty} \mathcal{L}(\theta; \mathcal{E}) \to \min \tag{1}$$

2.7 Tiến trình Chuyển tiếp từ Học máy sang Học sâu: Giới hạn và Động lực Đột phá

Sự phát triển của thị giác máy tính gắn liền với bước chuyển dịch từ các thuật toán học máy cổ điển sang các kiến trúc mạng nơ-ron sâu:

1. Quá trình chuyển dịch công nghệ: Trong thời kỳ học máy truyền thống (trước năm 2012), quy trình xử lý tách rời làm hai giai đoạn độc lập: (1) Trích xuất đặc trưng thủ công (Hand-crafted Feature Extraction) do con người thiết kế như SIFT (Lowe, 2004), HOG (Dalal & Triggs, 2005) hay LBP; (2) Đưa các vector đặc trưng này vào bộ phân loại nông như SVM (Cortes & Vapnik, 1995) hoặc Random Forest (Breiman, 2001). Ngược lại, kỷ nguyên học sâu tích hợp toàn bộ quy trình thành một mạng duy nhất theo cơ chế học biểu diễn đầu-cuối (End-to-End Representation Learning), ánh xạ trực tiếp từ pixel thô sang dự đoán ngữ nghĩa.

2. Những hạn chế căn bản của Học máy truyền thống:

- *Nút thắt cổ chai từ đặc trưng thủ công:* Các bộ trích xuất thủ công chỉ nắm bắt được các mẫu hình học cục bộ đơn giản (cạnh, góc, kết cấu xám), dễ mất tính bất biến trước các biến dạng phối cảnh lớn, che khuất hoặc thay đổi tư thế phức tạp.
- *Lời nguyền số chiều (Curse of Dimensionality):* Khi xử lý ảnh có độ phân giải cao, không gian đặc trưng bùng nổ khiến các thuật toán dựa trên ranh giới phẳng hoặc khoảng cách hình học bị suy giảm hiệu năng nghiêm trọng.
- *Sự bão hòa dung lượng mô hình:* Khi tăng quy mô dữ liệu từ hàng vạn lên hàng triệu mẫu, hiệu năng của các mô hình nông nhanh chóng đạt trần do dung lượng biểu diễn (Model Capacity) bị giới hạn.

3. Động lực thúc đẩy sự ra đời của Học sâu:

- *Tự động học biểu diễn phân cấp (Hierarchical Feature Abstraction):* Mạng nơ-ron sâu tự động trừu tượng hóa thông tin theo từng tầng: từ đường biên cục bộ ở tầng đầu, đến các bộ phận hình thể ở tầng giữa, và ngữ nghĩa đối tượng hoàn chỉnh ở tầng sâu nhất.
- *Định luật mở rộng quy mô (Scaling Laws):* Hiệu năng của học sâu liên tục tăng trưởng tương ứng với kích thước dữ liệu và số lượng tham số khi được hỗ trợ bởi năng lực tính toán GPU/TPU song song quy mô lớn.
- *Năng lực biểu diễn đa phương thức:* Khả năng liên kết biểu diễn đồng thời ảnh, video, văn bản và âm thanh vào cùng một không gian nhúng chung.

2.8 Nền tảng của Học sâu: Vì sao Nguyên lý Đơn giản tạo nên Khả năng Biểu diễn Vượt trội?

Về mặt toán học, mạng nơ-ron sâu được xây dựng từ các phép toán nền tảng:

1. Phép biến đổi affine tuyến tính: $\mathbf{z} = \mathbf{W}\mathbf{x} + \mathbf{b}$.
2. Phép kích hoạt phi tuyến cục bộ từng phần tử: $\mathbf{a} = \sigma(\mathbf{z})$ (với σ là hàm ReLU, GELU, Sigmoid).
3. Quá trình tối ưu hóa bằng giải thuật lan truyền ngược (Backpropagation) dựa trên quy tắc đạo hàm chuỗi (Chain Rule) và phương pháp hạ dốc độ dốc ngẫu nhiên (SGD (Robbins & Monro, 1951)).

Nguyên lý toán học này mang lại khả năng biểu diễn vượt trội nhờ ba cơ chế nền tảng:

- **Định lý Xấp xỉ Phổ quát (Universal Approximation Theorem):** Một mạng nơ-ron chứa các tầng ẩn phi tuyến có khả năng xấp xỉ bất kỳ hàm số liên tục nào với độ chính xác tùy ý. Khi xếp chồng nhiều tầng sâu, cấu trúc phân cấp cho phép mô hình biểu diễn các hàm logic phức tạp với số lượng tham số tiết kiệm hơn theo cấp số nhân so với mạng nông.
- **Cấu trúc thiên lệch cảm ứng (Inductive Bias):** Kiến trúc tích chập (Convolution) tận dụng tính chất bất biến tịnh tiến và tính tương quan cục bộ của hình ảnh tự nhiên, giúp thu hẹp không gian tìm kiếm tham số một cách tối ưu. Tương tự, cơ chế tự chú ý (Self-Attention) trong Vision Transformer mô hình hóa quan hệ phụ thuộc toàn cục linh hoạt.
- **Hình học tối ưu trong không gian tham số cao chiều:** Trong không gian hàng triệu đến hàng tỷ chiều, các điểm dừng tối ưu chủ yếu là các điểm yên ngựa (Saddle Points) mà giải thuật tối ưu hóa có thể vượt qua, giúp mô hình hội tụ về các vùng nghiệm có khả năng khái quát hóa cao.

2.9 Mô hình 5 Cấp độ Nhận thức và Dữ liệu: Ứng dụng Giám sát An ninh Trường học

Quá trình chuyển hóa dữ liệu từ dạng tín hiệu vật lý thô sang hành động có giá trị nhân văn được mô hình hóa qua **5 Cấp độ Nhận thức**:

1. **Level 1: Unfiltered Data (Dữ liệu thô chưa lọc):** Tín hiệu điểm ảnh, sóng âm, dữ liệu cảm biến chưa qua xử lý.

2. **Level 2: Pattern Information (Thông tin mẫu):** Các mẫu hình học, đặc trưng thị giác, vector nhúng được trích xuất có cấu trúc.
3. **Level 3: Predictability Knowledge (Tri thức có tính dự đoán):** Nhận định danh tính, xu hướng, mối liên hệ nhân quả và quy luật lịch sử.
4. **Level 4: Choice Intelligence (Trí thông minh ra quyết định):** Năng lực lựa chọn phương án hành động tối ưu trong các kịch bản thực thi.
5. **Level 5: Compassion Wisdom (Thông tuệ thấu cảm):** Sự đánh giá giá trị nhân văn, thấu hiểu hoàn cảnh và đưa ra giải pháp nhân bản.

Bảng 9 phân tích ma trận ứng dụng 5 cấp độ này vào bài toán **Hệ thống Giám sát An ninh & Điểm danh Khuôn mặt tại Trường học**, chỉ rõ từng Task, Cấp độ nhận thức tương ứng, Dữ liệu đầu vào, Dữ liệu đầu ra và Nội dung chi tiết trong từng ô.

Bảng 9: Ma trận phân tích 5 cấp độ nhận thức ứng dụng trong Hệ thống Giám sát An ninh Trường học

Task hệ thống	Cấp độ nhận thức	Dữ liệu đầu vào (Input)	Dữ liệu đầu ra (Output)	Nội dung chi tiết & Ví dụ minh họa trong ô
Task 1: Thu nhận luồng hình ảnh	**Level 1: Unfiltered Data**	Luồng tín hiệu video RTSP từ camera giám sát tại cổng trường	Mảng ma trận byte điểm ảnh thô $I_t \in \mathbb{R}^{H \times W \times 3}$	**[Mức 1 - Dữ liệu thô]:** Thu nhận 30 khung hình/giây chứa mọi thông tin nền (bóng râm, cây cối, xe cộ, ánh sáng đổi) mà máy tính chưa phân biệt được có học sinh hay không.
Task 2: Phát hiện & Trích xuất khuôn mặt	**Level 2: Pattern Information**	Khung ảnh thô I_t	Hộp bao khuôn mặt $\mathcal{B}$ và Vector nhúng đặc trưng $\mathbf{e} \in \mathbb{R}^{512}$	**[Mức 2 - Thông tin mẫu]:** Thuật toán RetinaFace định vị khuôn mặt và trích xuất vector 512 chiều biểu diễn cấu trúc hình học khoảng cách mắt, mũi, miệng.
Task 3: Định danh & Đối chiếu lịch sử	**Level 3: Predictability Knowledge**	Vector nhúng $\mathbf{e}$ kèm cơ sở dữ liệu học sinh $\mathcal{D}_{\text{student}}$	Danh tính học sinh kèm độ tin cậy, lịch sử chuyên cần	**[Mức 3 - Tri thức dự đoán]:** Xác định khuôn mặt là "Em An - Lớp 10A1" với độ khớp 99.4%; nhận diện học sinh đi trễ 3 ngày liên tiếp, dự báo nguy cơ vi phạm nền nếp.
Task 4: Điều khiển cổng & Cảnh báo tự động	**Level 4: Choice Intelligence**	Kết quả định danh và quy tắc an ninh trường học	Tín hiệu relay mở cổng / Gửi thông báo phụ huynh / Chuông báo	**[Mức 4 - Trí thông minh lựa chọn]:** Nếu là học sinh: tự động mở chốt cửa và gửi thông báo điểm danh cho phụ huynh; nếu phát hiện người lạ chưa đăng ký: tự động khóa cổng và báo bảo vệ.
Task 5: Đánh giá hoàn cảnh & Hỗ trợ nhân văn	**Level 5: Compassion Wisdom**	Nhật ký đi trễ, biểu cảm khuôn mặt mệt mỏi và dữ liệu gia cảnh	Đề xuất tư vấn tâm lý, hỗ trợ hoàn cảnh khó khăn	**[Mức 5 - Thông tuệ thấu cảm]:** Không trừ điểm thi đua máy móc; hệ thống ghi nhận học sinh đi trễ kèm biểu hiện kiệt sức, đề xuất giáo viên chủ nhiệm thăm hỏi gia cảnh và hỗ trợ tâm lý học đường.

2.10 Mô hình Giải pháp 3 Tầng trong Khoa học Dữ liệu Thị giác

Để xây dựng một hệ thống thị giác máy tính hoàn chỉnh phục vụ thực tiễn, kiến trúc kỹ thuật được chuẩn hóa thành **Mô hình Giải pháp 3 Tầng** (Bảng 10):

1. **Tầng 1: Kỹ thuật Cốt lõi / Nền tảng Thuật toán (Foundational Technologies):** Bao gồm các mô hình toán học, kiến trúc mạng nơ-ron nền tảng (CNN, Vision Transformer), hàm mất mát, thuật toán tối ưu (AdamW (Loshchilov & Hutter, 2019), SGD (Robbins & Monro, 1951)) và giải thuật hình học thị giác (Epipolar, Homography).
2. **Tầng 2: Tác vụ Thị giác Cơ sở (Core Vision Tasks):** Các khối chức năng thị giác cơ bản giải quyết các bài toán độc lập như Phân loại ảnh, Phát hiện hộp bao, Nhận dạng khuôn mặt, Ước lượng chiều sâu, Tách mặt nạ phân đoạn hay Theo dõi quỹ đạo.
3. **Tầng 3: Hệ thống Ứng dụng Nghiệp vụ Hoàn chỉnh (End-to-End Business Applications):** Tích hợp các khối chức năng ở Tầng 2 cùng các ràng buộc nghiệp vụ, giao diện người dùng, cơ sở dữ liệu và phần cứng điều khiển để tạo thành sản phẩm hoàn chỉnh giải quyết bài toán thực tế.

Bảng 10: Cấu trúc Mô hình Giải pháp 3 Tầng trong Thị giác máy tính

Phân tầng	Thành phần cốt lõi	Ví dụ minh họa cụ thể
Tầng 1: Kỹ thuật cốt lõi	Kiến trúc mạng (ResNet (He et al., 2016), Swin-ViT (Liu et al., 2021), YOLO-backbone (Redmon et al., 2016)), Hàm mất mát (ArcFace, InfoNCE, GIoU (Rezatofighi et al., 2019)), Thư viện tối ưu (PyTorch, TensorRT).	Mạng ResNet-50 (He et al., 2016) kết hợp hàm mất mát ArcFace tối ưu hóa bằng AdamW (Loshchilov & Hutter, 2019) trên tập dữ liệu chuẩn.
Tầng 2: Tác vụ thị giác	Các bài toán cơ sở: Face Detection, Facial Landmark Alignment, Re-Identification, Crowd Density Estimation.	Phát hiện 68 điểm mốc khuôn mặt và trích xuất vector đặc trưng khuôn mặt 512 chiều.
Tầng 3: Ứng dụng nghiệp vụ	Hệ thống hoàn chỉnh tích hợp cơ sở dữ liệu, phân quyền, cảnh báo thời gian thực và tự động hóa quy trình nghiệp vụ.	Hệ thống Kiosk tự động Check-in hành khách tại sân bay tích hợp cổng kiểm soát an ninh xuất nhập cảnh.

2.11 Khái quát các Nhóm Ứng dụng Cơ bản của Thị giác Máy tính

Thị giác máy tính hiện đại được phân bổ thành 5 nhóm ứng dụng công nghiệp trọng yếu (Bảng 11).

Bảng 11: Tổng hợp 5 nhóm lĩnh vực ứng dụng cơ bản của Thị giác máy tính

Lĩnh vực ứng dụng	Các tác vụ Tầng 2 tích hợp	Hệ thống sản phẩm Tầng 3 tiêu biểu
1. Giám sát an ninh & Đô thị thông minh	Detection, Tracking, License Plate Recognition, Crowd Counting.	Hệ thống camera phạt nguội giao thông tự động; Giám sát trật tự đô thị và an ninh sân bay.
2. Y tế số & Chẩn đoán hình ảnh	Semantic Segmentation, 3D Voxel Reconstruction, Anomaly Detection.	Phần mềm tự động khoanh vùng khối u trên ảnh chụp CT/MRI; Phát hiện sớm polyp nội soi tiêu hóa.
3. Tự hành & Robot công nghiệp	3D Object Detection, Depth Estimation, Visual SLAM, Optical Flow.	Hệ thống xe tự lái; Cánh tay robot tự động gắp thả linh kiện và kiểm tra lỗi hàn vi mạch.
4. Bán lẻ & Thương mại điện tử	Image Retrieval, Fine-grained Classification, Pose Estimation.	Tìm kiếm sản phẩm bằng hình ảnh trên sàn TMĐT; Cửa hàng bán lẻ tự động không người thu ngân.
5. Điện ảnh, CGI & Thực tế ảo (AR/VR)	3D Face Reconstruction, Motion Capture, Generative Video Inpainting.	Kỹ xảo điện ảnh kỹ thuật số (VFX); Tạo Avatar Metahuman; Bộ lọc hiệu ứng khuôn mặt AR trên smartphone.

2.12 Phân tích Chuyên sâu: Ứng dụng Trí tuệ Nhân tạo trong Ngành Điện ảnh

Ứng dụng AI trong phân tích trải nghiệm khán giả điện ảnh (AI for Cinema Audience Analysis) là ví dụ điển hình về sự phối hợp giữa Tầng 1, Tầng 2 và Tầng 3 nhằm tối ưu hóa giá trị nghệ thuật và thương mại (Bảng 12):

2.13 Ý nghĩa Thực tiễn của Bài toán Đếm Đám đông ở Tầng Ứng dụng Nghiệp vụ

Ở Tầng 2 (Tác vụ kỹ thuật), bài toán Đếm đám đông (Crowd Counting) giải quyết việc ánh xạ hình ảnh $I \in \mathbb{R}^{H \times W \times C}$ sang bản đồ mật độ liên tục $D(x, y)$ để ước lượng số thực thể $\hat{N} = \sum_{x,y} D(x, y)$.

Khi được triển khai lên **Tầng 3 (Hệ thống Ứng dụng Nghiệp vụ Thực tiễn)**, bài toán này mang lại giá trị quản trị và an toàn xã hội to lớn:

Bảng 12: Quy trình phân tích trải nghiệm khán giả điện ảnh ứng dụng AI

Giai đoạn phân tích	Công nghệ & Tác vụ thị giác (Tầng 1 & 2)	Giá trị ứng dụng nghiệp vụ điện ảnh (Tầng 3)
1. Nhận diện khuôn mặt & Cảm xúc	Camera hồng ngoại trong rạp tối → Facial Landmark Detection → Phân loại biểu cảm (Vui mừng, Sợ hãi, Bất ngờ, Thất vọng) theo hệ thống mã hóa hành vi nét mặt FACS.	Đo lường chính xác mức độ kích thích cảm xúc của người xem tại từng cảnh phim; kiểm chứng xem phân đoạn phim có đạt hiệu ứng mong muốn (ví dụ cảnh hài có làm khán giả cười hay không).
2. Phân tích hành vi & Hướng nhìn	Head Pose Estimation, Eye Gaze Tracking → Action Recognition (che mắt, ngả người ra sau, quay sang người bên cạnh, xem điện thoại).	Đánh giá mức độ tập trung (Engagement Level) của khán giả; phát hiện các phân đoạn gây buồn ngủ hoặc nhàm chán khiến khán giả phân tâm.
3. Đồng bộ Timeline & Tối ưu kịch bản	Tích hợp chuỗi thời gian cảm xúc khán giả đồng bộ với biểu đồ Timeline dựng phim (Cut-by-cut synchronization).	Hỗ trợ đạo diễn và nhà sản xuất trong khâu chiếu thử nghiệm (Test Screening): cắt gọt các phân đoạn lê thê, tinh chỉnh nhịp độ (Pacing), dự báo doanh thu phòng vé và định hướng chiến dịch Marketing.

- **Phòng ngừa thảm họa giẫm đạp (Stampede Prevention):** Tại các sự kiện lễ hội, nhà ga tàu điện ngầm hoặc sân vận động, hệ thống liên tục tính toán mật độ cục bộ (người/m^2). Khi mật độ vượt ngưỡng an toàn (> 4 người/m^2), hệ thống tự động kích hoạt cảnh báo nguy cơ tắc nghẽn cục bộ để lực lượng an ninh kịp thời phân luồng trước khi xảy ra tai nạn.
- **Tối ưu hóa phân bổ nguồn lực công cộng:** Dữ liệu mật độ thời gian thực giúp cơ quan quản lý điều phối tần suất phương tiện giao thông công cộng, bố trí nhân viên cứu hộ và mở thêm cửa thoát hiểm linh hoạt.
- **Phân tích hành vi tiêu dùng và quy hoạch thương mại:** Đếm lưu lượng người đi bộ qua các gian hàng trong trung tâm thương mại giúp xác định các vị trí tập trung đông khách để định giá mặt bằng cho thuê và tối ưu hóa vị trí đặt biển quảng cáo.

2.14 Phân tích Hệ thống Tái tạo Khuôn mặt 3D theo Mô hình Giải pháp 3 Tầng

Hệ thống tái tạo khuôn mặt 3D (3D Face Reconstruction) từ ảnh 2D đơn góc nhìn là minh chứng tiêu biểu cho kiến trúc phân tầng hoàn chỉnh từ lý thuyết toán học đến ứng dụng thực tế (Bảng 13).

Tài liệu

Josh Abramson, Jonas Adler, Jack Dunger, Richard Evans, Tim Green, Alexander Pritzel, Olaf Ronneberger, Lindsay Willmore, Andrew J. Ballard, Joshua Bambrick, et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3. *Nature*, 630(8016):493–500, 2024. doi: 10.1038/s41586-024-07487-w.

Herbert Bay, Andreas Ess, Tinne Tuytelaars, and Luc Van Gool. Speeded-up robust features (SURF). *Computer Vision and Image Understanding*, 110(3):346–359, 2008. doi: 10.1016/j.cviu.2007.09.014.

Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. doi: 10.1023/A:1010933404324.

Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *European Conference on Computer Vision (ECCV)*, pp. 213–229. Springer, 2020.

Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995. doi: 10.1007/BF00994018.

Bảng 13: Phân tích hệ thống Tái tạo Khuôn mặt 3D theo Mô hình Giải pháp 3 Tầng

Phân tầng	Nhiệm vụ & Thành phần kỹ thuật	Chi tiết giải pháp công nghệ
Tầng 1: Kỹ thuật cốt lõi	Cơ sở mô hình toán hình học 3D, kiến trúc mạng nơ-ron và hàm tối ưu khả vi (Differentiable Rendering).	Mô hình tham số hình học 3D Morphable Model (3DMM: BFM, FLAME); Mạng Transformer trích xuất hệ số hình dạng $\boldsymbol{\alpha}$, biểu cảm $\boldsymbol{\beta}$ và tư thế $\mathbf{p}$; Hàm mất mát Photometric Consistency Loss, Landmark Reprojection Loss, và Perceptual Identity Loss.
Tầng 2: Tác vụ thị giác cơ sở	Các khối trích xuất thông tin trung gian từ ảnh 2D sang không gian 3D.	Phát hiện 68/468 điểm mốc 3D (Dense Facial Landmarks); Ước lượng trường độ sâu đơn sắc (Monocular Depth Estimation); Tách bản đồ phản xạ ánh sáng (Albedo/Texture UV Map) và góc chiếu sáng (Spherical Harmonics).
Tầng 3: Ứng dụng nghiệp vụ hoàn chỉnh	Tích hợp vào các phần mềm ứng dụng phục vụ người dùng cuối.	• **Y tế & Thẩm mỹ:** Mô phỏng kết quả phẫu thuật chỉnh hình hàm mặt trước khi phẫu thuật thực tế. • **Giải trí & Game:** Tự động tạo Digital Avatar 3D cá nhân hóa có khả năng cử động khớp thời gian thực trong game và không gian thực tế ảo. • **Bảo mật sinh trắc học:** Xác thực khuôn mặt 3D chống giả mạo (Face Anti-spoofing) ngăn chặn hành vi vượt rào bằng ảnh in 2D hoặc màn hình kỹ thuật số.

Wenliang Dai, Junnan Li, Dongxu Li, Anthony Meng Huat Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven C. H. Hoi. Instructblip: Towards general-purpose vision-language models with instruction tuning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pp. 49250–49267, 2023.

Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*, volume 1, pp. 886–893, 2005. doi: 10.1109/CVPR.2005.177.

Henghui Ding, Chang Liu, Shuting He, Kaining Ying, Xudong Jiang, Chen Change Loy, and Yu-Gang Jiang. Mevis: A multi-modal dataset for referring motion expression video segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 47(12):11400–11416, 2025. doi: 10.1109/TPAMI.2025.3600507.

Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.

Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 27, pp. 2672–2680, 2014.

Tianrui Guan, Fuxiao Liu, Xiyang Wu, Ruiqi Xian, Zongxia Li, Xiaoyu Liu, Xijun Wang, Lichang Chen, Furong Huang, Yaser Yacoob, Dinesh Manocha, and Tianyi Zhou. Hallusionbench: An advanced diagnostic suite for entangled language hallucination and visual illusion in large vision-language models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 14375–14385, 2024.

Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016. doi: 10.1109/CVPR.2016.90.

Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. In *International Conference on Learning Representations (ICLR)*, 2019.

Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pp. 6840–6851, 2020.

Hervé Jégou, Matthieu Douze, and Cordelia Schmid. Product quantization for nearest neighbor search. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33(1):117–128, 2011. doi: 10.1109/TPAMI.2010.57.

John Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool, Russ Bates, Augustin Žídek, Anna Potapenko, et al. Highly accurate protein structure prediction with AlphaFold. *Nature*, 596(7873):583–589, 2021. doi: 10.1038/s41586-021-03819-2.

Diederik P. Kingma and Max Welling. Auto-encoding variational Bayes. In *International Conference on Learning Representations (ICLR)*, 2014.

Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. ImageNet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 25, pp. 1097–1105, 2012.

Harold W. Kuhn. The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1-2):83–97, 1955. doi: 10.1002/nav.3800020109.

Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *International Conference on Machine Learning*, pp. 12888–12900. PMLR, 2022.

Lin Li, Haoyan Guan, Jianing Qiu, and Michael Spratling. One prompt word is enough to boost adversarial robustness for pre-trained vision-language models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 24676–24685, 2024.

Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. Evaluating object hallucination in large vision-language models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pp. 292–305, 2023.

Yuhong Li, Xiaofan Zhang, and Deming Chen. CSRNet: Dilated convolutional neural networks for understanding the highly congested scenes. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1091–1100, 2018.

Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.

Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations (ICLR)*, 2023.

Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pp. 34892–34916, 2023.

Wei Liu, Dragomir Anguelov, Dumitru Erhan, Christian Szegedy, Scott Reed, Cheng-Yang Fu, and Alexander C. Berg. SSD: Single shot multibox detector. In *European Conference on Computer Vision (ECCV)*, pp. 21–37. Springer, 2016.

Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin Transformer: Hierarchical vision transformer using shifted windows. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 10012–10022, 2021.

Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations (ICLR)*, 2019.

David G. Lowe. Distinctive image features from scale-invariant keypoints. *International Journal of Computer Vision*, 60(2):91–110, 2004. doi: 10.1023/B:VISI.0000029664.99615.94.

OpenAI. GPT-4V(ision) system card. *OpenAI Technical Report*, 2023. URL `https://openai.com/research/gpt-4v-system-card`.

William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 4195–4205, 2023.

Jean Piaget. *The Psychology of Intelligence*. Routledge & Kegan Paul, London, 1950. URL `http://www.jstor.org/stable/2088298`. Translated by Malcolm Piercy and D. E. Berlyne; Original French edition 1947.

Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pp. 8748–8763. PMLR, 2021.

Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 779–788, 2016.

Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster R-CNN: Towards real-time object detection with region proposal networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 28, pp. 91–99, 2015.

Hamid Rezatofighi, Nathan Tsoi, Jianwei Geng, Rui Deng, Stefan Leutenegger, and Silvio Savarese. Generalized intersection over union: A metric and a loss for bounding box regression. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 658–666, 2019.

Herbert Robbins and Sutton Monro. A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407, 1951. doi: 10.1214/aoms/1177729586.

Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.

Boyu Wang, Huidong Liu, Dimitris Samaras, and Minh Hoai. Distribution matching for crowd counting. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pp. 1595–1607, 2020.

Chuanqi Zang, Hanqing Wang, Mingtao Pei, and Wei Liang. Discovering the real association: Multimodal causal reasoning in video question answering. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 19027–19036, 2023.

Yifu Zhang, Peize Sun, Yi Jiang, Dongdong Yu, Fucheng Weng, Zehuan Yuan, Ping Luo, Wenyu Liu, and Xinggang Wang. ByteTrack: Multi-object tracking by associating every detection box. In *European Conference on Computer Vision (ECCV)*, pp. 1–21. Springer, 2022.

Zhaohui Zheng, Ping Wang, Wei Liu, Jinze Li, Rongguang Ye, and Dongwei Ren. Distance-IoU loss: Faster and better learning for bounding box regression. In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, volume 34, pp. 12993–12900, 2020.